

# Análisis de Sentimientos en Redes Sociales para Mattelsa

Laura Riveros Quintero  
ltriversq@eafit.edu.co

Mariel Viviana Sánchez Gamba  
mvsanchezg@eafit.edu.co



20 de marzo de 2025

---

# Índice

<b>1. Introducción</b>	<b>2</b>
1.1. Problema del negocio . . . . .	2
1.2. Impacto de la solución . . . . .	2
1.3. Objetivos . . . . .	2
1.4. Problema . . . . .	3
<b>2. Desarrollo metodológico</b>	<b>4</b>
2.1. Análisis Exploratorio de Datos . . . . .	4
2.2. Modelo . . . . .	5
2.2.1. Redes Neuronales Convolucionales (CNNs) . . . . .	5
2.3. Algoritmos de optimización y búsqueda local . . . . .	6
2.3.1. Simulated Annealing . . . . .	6
2.3.2. Algoritmo Genético . . . . .	7
2.4. Resultados . . . . .	7
2.5. Conclusión . . . . .	9

---

# 1. Introducción

Mattelsa es una marca de ropa que se ha caracterizado por la confección de prendas con mensajes de sensibilización. Esta compañía nació como una comercializadora de ropa de marcas nacionales y extranjeras pero que hoy no solo distribuye sus propios productos, sino un mensaje activista que busca el cuidado del medio ambiente y la estabilidad emocional” (El Colombiano, 2023).

## 1.1. Problema del negocio

Mattelsa enfrenta el desafío de medir y evaluar la efectividad de sus mensajes activistas y cómo estos impactan en su imagen de marca. Aunque sus productos son bien recibidos, no existe una herramienta sistemática que permita identificar:

- ¿Qué mensajes generan mayor resonancia emocional en su público?
- ¿Cómo las percepciones del público afectan sus decisiones de compra?
- ¿Qué áreas de mejora existen para alinear las estrategias de marketing con las expectativas del consumidor?

Estas preguntas representan una oportunidad para afinar estrategias de marketing y fortalecer la conexión emocional con sus clientes.

## 1.2. Impacto de la solución

Primero, es fundamental realizar una clasificación del tipo de contenido que se publica en las redes sociales. Esto nos permitirá identificar qué tipo de mensajes o contenido está generando más valor para la marca Mattelsa. Al entender las preferencias y tendencias de los usuarios, podremos determinar qué tipo de interacción y comunicación está siendo más efectiva.

## 1.3. Objetivos

- **Objetivo General:** Clasificar las imágenes de las publicaciones que se realizan por medio de redes sociales de la marca Mattelsa para comprender la percepción del consumidor y mejorar la estrategia de comunicación de la marca.
- **Objetivos Específicos:**
  - Identificar las publicaciones predominantes en las redes sociales de Mattelsa, teniendo en cuenta los dos tipos de contenido que sube la marca a sus redes sociales.

- Clasificar las imágenes utilizando herramientas de Machine Learning.
- Mejorar las predicciones del modelo mediante el uso de algoritmos de optimización y búsqueda local.

## 1.4. Problema

En el Instagram de la marca se presentan estos dos tipos de imágenes:

- Imágenes de producto




Figura 1: Imágenes de producto

- Imágenes de activismo y cultura popular



Figura 2: Imágenes de activismo y cultura popular

Estos dos tipos de publicaciones generan comentarios significativamente diferentes por parte de los consumidores. En el caso de las imágenes de productos, los comentarios suelen centrarse

---

en aspectos como el precio, la calidad y el estilo de la ropa ofrecida. Por otro lado, las imágenes relacionadas con activismo tienden a inspirar interacciones más informales, como la etiqueta de amigos, referencias a conocidos o incluso comentarios humorísticos. La idea de este análisis es filtrar únicamente aquellas publicaciones de producto

## **2. Desarrollo metodológico**

El entendimiento del problema se basa en el hecho de que, semanalmente, se generan en cierto número de publicaciones, lo que implica la necesidad de gestionar, clasificar y analizar un volumen considerable de contenido.

Actualmente, el equipo de marca elabora un informe mensual que evalúa el rendimiento de las publicaciones mediante indicadores obtenidos a través de la red social. Estas métricas permiten conocer el impacto de las publicaciones las cuales se dividen en dos categorías principales: fotografía y marca. El objetivo de estos indicadores es generar retroalimentación específica para los diferentes equipos, fotografía y diseñadores de moda que se enfocan en todo lo relacionado a producto y diseñadores gráficos, que son los encargados de las ilustraciones. Sin embargo, este proceso de clasificación se realiza de forma manual, lo que resulta complejo y consume una cantidad significativa de tiempo.

Dado el volumen de publicaciones y la necesidad de agilizar el proceso, se propone entrenar un modelo de clasificación de imágenes capaz de automatizar este flujo de trabajo, mejorando la eficiencia y reduciendo la carga manual del equipo.

### **2.1. Análisis Exploratorio de Datos**

Para el análisis se dispone de diferentes fuentes de información. Inicialmente, se cuenta con un total de 4,598 imágenes previamente clasificadas en cinco categorías. Sin embargo, para este análisis se realizará una reducción de dichas categorías, dado que en la actualidad el negocio trabaja únicamente con dos clasificaciones principales: fotografía y marca. Estas categorías representan las más relevantes para el modelo, siendo fotografía el 70 % de las imágenes clasificadas, es decir, un conjunto de 2,900 imágenes y marca el 30 % que corresponde a un total de 1223 imágenes.




Figura 3: Etiquetas de cada uno de los registros obtenidos

## 2.2. Modelo

### 2.2.1. Redes Neuronales Convolucionales (CNNs)

Las Redes Neuronales Convolucionales fueron seleccionadas como modelo principal para la clasificación de imágenes debido a su alta precisión y capacidad para manejar datos visuales complejos. A continuación, se detallan las razones clave para esta elección:

- **Clasificación de imágenes complejas:** Las CNNs son capaces de identificar diferencias sutiles entre imágenes de productos y de activismo, gracias a su habilidad para capturar patrones visuales jerárquicos.
- **Impacto comercial:** La alta precisión de las CNNs garantiza una clasificación confiable, minimizando errores que podrían afectar decisiones estratégicas relacionadas con campañas publicitarias y análisis de productos.
- **Flexibilidad y adaptabilidad:** Mediante técnicas como transferencia de aprendizaje, las CNNs pueden aprovechar redes preentrenadas (por ejemplo, ResNet o VGG), lo que las hace adecuadas para trabajar con volúmenes moderados de datos y mejorar el rendimiento del modelo.
- **Detección de características relevantes:** Las CNNs trabajan directamente con píxeles de la imagen y extraen automáticamente características visuales relevantes, eliminando la necesidad de procesamiento intensivo o diseño manual de características.
- **Robustez frente a variaciones:** Este modelo es resiliente frente a variaciones en las imágenes, como rotaciones, cambios de escala o diferentes condiciones de iluminación, lo que asegura una mayor generalización al clasificar nuevos datos.

- 
- **Reconocimiento visual avanzado:** Dado que las imágenes de activismo pueden incluir elementos abstractos (como memes o animaciones) y las de productos presentan detalles específicos, las CNNs destacan en la identificación y clasificación basándose en relaciones visuales jerárquicas.

## 2.3. Algoritmos de optimización y búsqueda local

### 2.3.1. Simulated Annealing

Algoritmo de optimización inspirado en el proceso físico de enfriamiento de metales. Su objetivo es encontrar una solución óptima o casi óptima a un problema de optimización en un espacio de soluciones grandes y complejas, donde otros métodos podrían quedarse atrapados en soluciones subóptimas (mínimos locales). Este algoritmo es especialmente útil cuando se busca resolver problemas en los que el espacio de soluciones es vasto.

1. **Inicialización:** El algoritmo comienza con una *solución inicial* aleatoria o proporcionada por un experto en el problema. Además, se asigna una *temperatura inicial* y una tasa de enfriamiento, que son parámetros cruciales para controlar el proceso de búsqueda y optimización.
2. **Evaluación de la solución:** La calidad de la solución generada en cada iteración se mide mediante una *función objetivo*, que evalúa qué tan buena es la solución en relación al problema que se está tratando de optimizar. La función objetivo es utilizada para determinar si la nueva solución es mejor o peor que la actual.
3. **Iteración principal:** En cada ciclo del algoritmo, se genera una *nueva solución vecina* a partir de la solución actual. Si la nueva solución es *mejor*, se acepta inmediatamente. Si es *peor*, se acepta con una probabilidad  $P$  calculada como:

$$P = \exp\left(-\frac{\Delta E}{T}\right)$$

donde  $\Delta E$  es la diferencia de la función objetivo entre la nueva y la actual, y  $T$  es la temperatura actual.

4. **Enfriamiento:** Después de cada iteración, la *temperatura* se reduce gradualmente, lo que disminuye la probabilidad de aceptar soluciones peores. Este proceso de enfriamiento simula la reducción de energía en el proceso físico del recocido de metales.
5. **Criterio de parada:** El algoritmo de recocido simulado se detiene cuando se cumple alguno de los siguientes criterios: (1) la temperatura alcanza un valor mínimo predefinido, (2) se alcanza un número máximo de iteraciones, o (3) se encuentra una solución suficientemente buena o el algoritmo converge.

---

### 2.3.2. Algoritmo Genético

Técnica de optimización y búsqueda inspirada en los principios de la evolución natural y la selección natural, propuestos por Charles Darwin. Esta metodología se utiliza para resolver problemas complejos de optimización, donde la solución no se puede encontrar mediante métodos tradicionales debido a la alta complejidad del espacio de soluciones. Los algoritmos genéticos simulan los procesos biológicos, como la herencia, la mutación y la selección natural, para encontrar soluciones cercanas a la óptima.

1. **Inicialización:** Crear una población inicial de soluciones aleatorias.
2. **Evaluación:** Calcular la aptitud de cada individuo en la población utilizando la función de aptitud.
3. **Selección:** Seleccionar un subconjunto de individuos de la población según su aptitud para generar descendencia.
4. **Cruzamiento:** Realizar cruzamientos entre los individuos seleccionados para crear nuevos descendientes.
5. **Mutación:** Aplicar mutaciones aleatorias a los descendientes para explorar nuevas soluciones.
6. **Reemplazo:** Reemplazar a los individuos antiguos con los nuevos descendientes y repetir el proceso durante varias generaciones.
7. **Criterio de parada:** El proceso termina cuando se alcanza un número máximo de generaciones o cuando se encuentra una solución suficientemente buena.

### 2.4. Resultados

En este trabajo, se utilizaron dos algoritmos de optimización y búsqueda para encontrar los mejores hiperparámetros que permitieran mejorar el rendimiento de una red neuronal convolucional en la clasificación de imágenes.

Los algoritmos implementados fueron:

- **Algoritmo Genético (GA)**
- **Simulated Annealing (SA)**

El objetivo principal era evaluar cuál de estos métodos encontraba la configuración óptima para la red, maximizando la precisión del modelo en el conjunto de validación.



---

## Hiperparámetros Ajustados:

Para ambos algoritmos, se optimizaron los siguientes hiperparámetros:

- **Número de neuronas en cada capa convolucional:** que afecta la cantidad de filtros usados para extraer características de las imágenes.
- **Número de neuronas en la capa densa:** que influye en la capacidad de clasificación del modelo.
- **Dropout:** una técnica utilizada para reducir el sobreajuste al desactivar aleatoriamente algunas neuronas durante el entrenamiento.

Los valores considerados para cada hiperparámetro fueron los siguientes:

- **Número de neuronas en las capas convolucionales:** {16, 32, 64, 128}
- **Número de neuronas en la capa densa:** {128, 256, 512}
- **Dropout:** {0.3, 0.5, 0.7}

## Proceso de Optimización:

El procedimiento seguido en ambos algoritmos fue el siguiente:

1. Se generó una configuración inicial de hiperparámetros dentro de los valores establecidos.
2. Se entrenó el modelo con esta configuración y se evaluó su precisión en el conjunto de validación.
3. Se aplicaron las estrategias de cada optimizador para generar nuevas combinaciones de hiperparámetros:
  - En el **Algoritmo Genético:** se aplicaron operadores de mutación y cruce para explorar mejores configuraciones.
  - En **Simulated Annealing:** se aceptaron nuevas configuraciones con una probabilidad dependiente de la temperatura, permitiendo escapar de óptimos locales.
4. Se repitió el proceso durante varias iteraciones hasta que la mejora en la precisión del modelo se estabilizó.

---

Se comparo el desempeño de ambos métodos y se determino cuál lograba la mejor configuración para la red neuronal convolucional.

Los hiperparamtros que daban mejores resultados en la precisión del modelo para cada optimizador fueron los siguientes:

Optimizador	Capa 1	Capa 2	Capa 3	Dropout	Dense units	acuraccy
Simulated Annealing	16	64	16	0.3	512	0.94
Genetic Algorithm	58	118	68	0	274	0.92

Cuadro 1: Mejor configuración encontrada

## 2.5. Conclusión

### Comparación de Resultados

Al comparar ambos algoritmos, Simulated Annealing alcanzó un 94 % de accuracy, mientras que Genetic Algorithm obtuvo un 92 %. Esto indica que Simulated Annealing logró encontrar una mejor combinación de hiperparámetros para mejorar el rendimiento del modelo.

En cuanto a la estructura de la red, Simulated Annealing usó menos neuronas en la segunda capa (64 vs. 118 en GA), pero más en la capa densa final (512 vs. 274 en GA). Esto sugiere que Simulated Annealing priorizó una mejor representación en la etapa final del modelo, mientras que Genetic Algorithm distribuyó más neuronas en las capas intermedias.

Tambien el uso de dropout, ayuda a evitar el sobreajuste. Simulated Annealing aplicó un dropout de 0.3, mientras que Genetic Algorithm no usó dropout (0). Esto pudo haber ayudado a que Simulated Annealing generalizara mejor, evitando que el modelo memorizara demasiado los datos de entrenamiento.

Los resultados muestran que Simulated Annealing encontró una mejor configuración y obtuvo una mayor precisión. Esto puede deberse a una mejor distribución de neuronas y al uso de dropout, que ayudó a que el modelo funcionara mejor en datos nuevos.